


Comparação de testes de normalidade

Anaih P. Pereira e Arthur C. M. Rocha

3 de outubro de 2017



Criando uma função para aplicação dos testes de normalidade:

```
testes<-function(t){  
  
s<-shapiro.test(t)  
l<-lillie.test(t)  
a<-ad.test(t)  
c<-cvm.test(t)  
p<-pearson.test(t)  
k<-ks.test(t,"pnorm",mean(t),sd(t))  
  
tabela<-data.frame(Teste=c("SW","Lillie","AD","CVM","Chisq","KS"),  
                    Estatística=c(s$statistic,l$statistic,a$statistic,  
                                   c$statistic,p$statistic,k$statistic),  
                    Valor_p=c(s$p.value,l$p.value,a$p.value,  
                               c$p.value,p$p.value,k$p.value))  
  
return(tabela)  
}
```

Utilizando um banco de dados para aplicar os testes:

Foram feitos os testes para as variáveis peso (com outliers) e peso (sem outliers), idade e altura. A partir dos valores-p obtidos pelos testes, é perceptível que a hipótese nula de normalidade é rejeitada em todos os casos. Os resultados são apresentados nas tabelas abaixo:

- Para os pesos:

```
testes(dados$Peso)      #com outliers
```

##	Teste	Estatística	Valor_p
## 1	SW	0.95033571	7.832850e-11
## 2	Lillie	0.08197083	2.644292e-07
## 3	AD	4.40445109	6.019804e-11
## 4	CVM	0.66634124	1.101321e-07
## 5	Chisq	109.59069767	2.332194e-14
## 6	KS	0.08197083	6.186539e-03

```
testes(Peso)            #sem outliers
```

##	Teste	Estatística	Valor_p
## 1	SW	0.96760228	4.655856e-08
## 2	Lillie	0.08601399	6.013929e-08
## 3	AD	3.77567998	1.992169e-09
## 4	CVM	0.58565319	4.773640e-07
## 5	Chisq	83.27186761	1.085340e-09
## 6	KS	0.08601399	3.826119e-03

- Para altura:

```
testes(dados$Altura)    #altura
```

##	Teste	Estatística	Valor_p
## 1	SW	0.95433619	2.854688e-10
## 2	Lillie	0.05966594	8.933214e-04
## 3	AD	1.03273601	1.012611e-02
## 4	CVM	0.13842407	3.377685e-02

```
## 5  Chisq 90.33488372 6.477535e-11
## 6    KS  0.05966594 9.361395e-02
```

- Para idade:

```
testes(dados$Idade) #idade
```

```
##      Teste Estatística      Valor_p
## 1      SW    0.7861826 2.442673e-23
## 2 Lillie    0.1598575 7.923437e-30
## 3      AD   17.2874648 3.700000e-24
## 4      CVM    2.6076726 7.370000e-10
## 5  Chisq  680.2046512 3.402296e-131
## 6      KS    0.1598575 5.709836e-10
```

Utilizando outro banco de dados para aplicar os testes:

Foram feitos os testes para as variáveis peso, altura, número de filhos. A partir dos valores-p obtidos pelos testes, é perceptível que a hipótese nula de normalidade não é rejeitada para a variável peso. Para a variável altura, o teste qui-quadrado foi o único a rejeitar a hipótese nula, enquanto que para a variável número de filhos todos os testes rejeitaram a hipótese de normalidade. Os resultados são apresentados nas tabelas abaixo:

- Para peso:

```
testes(dados2$peso)
```

```
##      Teste Estatística      Valor_p
## 1      SW  0.99496046 0.3496246
## 2 Lillie  0.02413216 0.9083980
## 3      AD  0.24366416 0.7633791
## 4      CVM  0.03132502 0.8282354
## 5  Chisq 13.65765766 0.7511198
## 6      KS  0.02413216 0.9901730
```

- Para altura:

```
testes(dados2$altura)
```

```
##      Teste Estatística      Valor_p
## 1      SW  0.99472258 0.3102498798
## 2 Lillie  0.04745225 0.0682086686
## 3      AD  0.54392554 0.1611879381
## 4      CVM  0.09594664 0.1273451103
## 5  Chisq 42.79279279 0.0008559786
## 6      KS  0.04745225 0.4414589884
```

- Para numero de filhos:

```
testes(dados2$Numerofilhos)
```

```
##      Teste Estatística      Valor_p
## 1      SW    0.8710386 1.991316e-08
## 2 Lillie    0.2292453 6.465507e-16
## 3      AD    6.8839748 5.814830e-17
## 4      CVM    1.2440423 7.370000e-10
## 5  Chisq 412.7500000 1.199785e-81
## 6      KS      NA      NA
```

Simulações para achar o poder dos testes:

- Definições Gerais

```
set.seed(12345)

namostra<-round(seq(10,2000,,25)) #tamanhos da amostra

poder<-list() #lista vazia para guardar os poderes
```

- A partir de simulações, foram geradas amostras de tamanhos entre 0 e 2000 de uma v.a Beta(2,2) e aplicados os testes de normalidade, a fim de obter-se o poder do teste (1-erro do tipo II), para isso extraiu-se os valores-p dos testes e contabilizaram-se a quantidade de testes onde a hipótese nula (normalidade) não foi rejeitada e assim, fazendo a diferença de 1 e essa quantidade, estimou-se empiricamente o poder dos testes.

- Os códigos a seguir representam as simulações:

```
for(i in 1:length(namostra)){

  boot<-replicate(500,{
    x<-rbeta(namostra[i],2,2)
    ks<-ks.test(x,"pnorm",mean(x),sd(x))$p.value
    sw<-shapiro.test(x)$p.value
    lilli<-lillie.test(x)$p.value
    ad<-ad.test(x)$p.value
    cvm<-cvm.test(x)$p.value
    chi<-pearson.test(x)$p.value
    c(ks,sw,lilli,ad,cvm,chi)
  })


  b<-apply(boot,1,function(x) return(x>.05))
  testes<-apply(b,2,mean)
  names(testes)<-c('ks','sw','lilli','ad','cvm','chi')
  poder[[i]]<-1-testes
}
```

Gráfico dos poderes

Usando o pacote ggplot2, fez-se o gráfico dos poderes dos testes conforme o número de amostra

```
library(ggplot2)

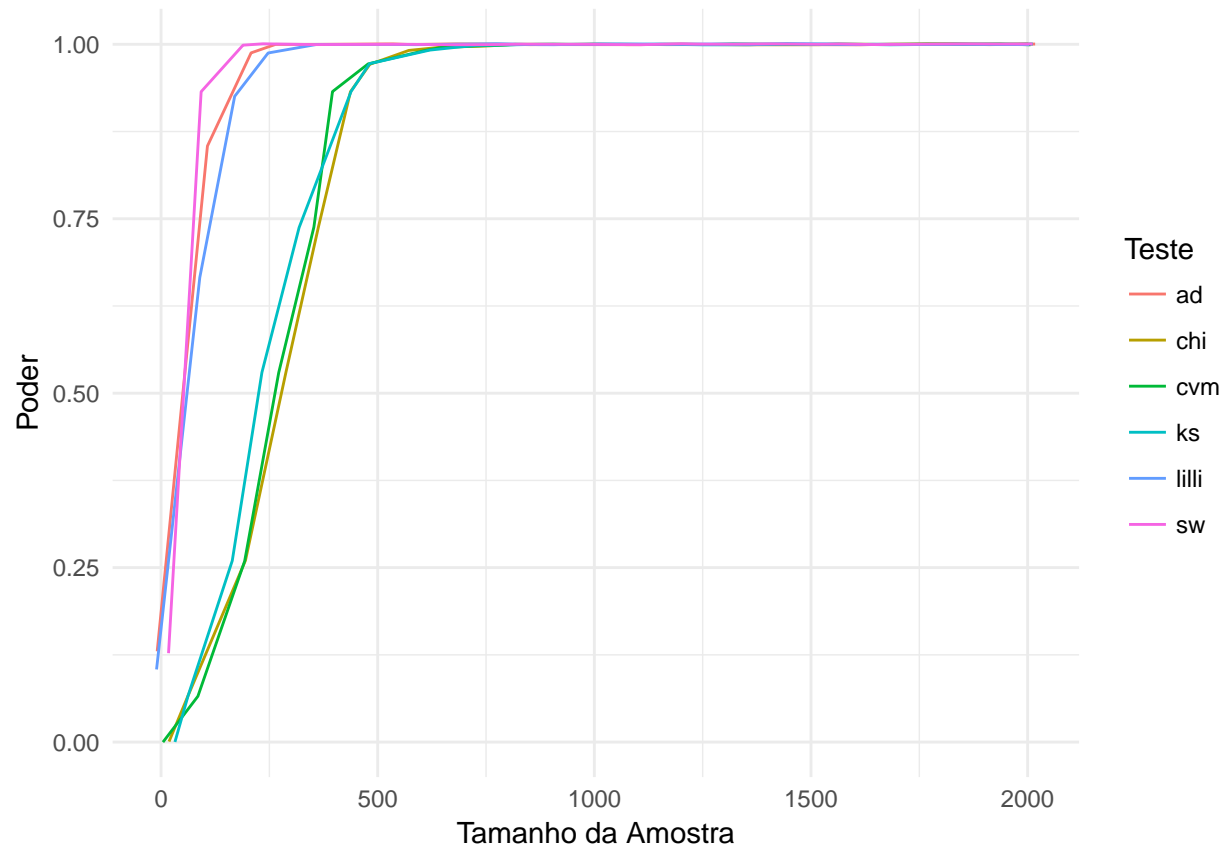
#criando o data frame para o ggplot
dt<-data.frame(rep(namostra,6),c(ks,sw,lilli,ad,cvm,chi))
dt$teste<-rep(c("ks","sw","lilli","ad","cvm","chi"),each=25)
names(dt)<-c("namostra","Poder","Teste")
plot<-ggplot(dt,aes(namostra,Poder,group=Teste,col=Teste))+geom_line(position="jitter")
plot<-plot+theme_minimal() + xlab("Tamanho da Amostra")
plot
```



É perceptível que a classificação quanto ao poder foi:


```
## [1] "sw"    "ad"    "lilli" "chi"   "cvm"   "ks"
```

- Análogamente, fez-se simulações de amostras de uma v.a com distribuição $\text{Gamma}(4,5)$, obtendo-se o seguinte resultado:



Resultados:

- Observou-se, pelos estudos que a classificação de poder é:



*

*